Introdução ao R para Análise de Dados

Minicurso

Paulo Alexandrino

Março 2023

Sumário

Capítulo 1

Conceitos Fundamentais

1.1 Operadores

1.1.1 Operadores matemáticos

A forma mais elementar de utilizar o R é como uma calculadora que nos permite realizar todo tipo de operação matemática desejada.

```
# Soma (+)
5 + 7
```

```
## [1] 12
```

```
# Subtração (-)
10 - 16
```

```
## [1] -6
```

```
# Multiplicação (*)
2 * 7
```

```
## [1] 14
```

```
# Exponenciação (^)
2^4
```

```
## [1] 16
```

```r
# Divisão (/)
5 / 2
```

```
## [1] 2.5
```

```r
# Divisão Inteira (%/%)
5 %/% 2
```

```
## [1] 2
```

```r
# Módulo - Resto da divisão inteira (%%)
5 %% 2
```

```
## [1] 1
```

1.1.2 Operadores lógicos

Operadores lógicos nos permitem estabelecer relações entre objetos e julgar proposições (orações declarativas) como verdadeiras (`TRUE`) ou falsas (`FALSE`). Serão muito úteis a construção de filtros.

```r
# Menor que (<)
5 < 3
```

```
## [1] FALSE
```

```r
# Menor ou igual que (<=)
2.5 <= 7
```

```
## [1] TRUE
```

```r
# Maior que (>)
10 > 15
```

```
## [1] FALSE
```

```r
# Maior ou igual que (>=)
11 >= 11
```

```
## [1] TRUE
```

```r
# Igual a (==)
2 == 3
```

```
## [1] FALSE
```

```r
# Diferente de (!=)
5 != 4
```

```
## [1] TRUE
```

A negação de uma proposição é seu inverso lógico.

```r
# Negação (!)
2 > 5
```

```
## [1] FALSE
```

```r
!(2 > 5)
```

```
## [1] TRUE
```

Os conectivos de conjunção ($\wedge$, lê-se `E`) e disjunção ($\vee$, lê-se `OU`) são operadores lógicos que permitem criar proposições compostas. Sejam p e q proposições quaisquer:

- A conjunção $p \wedge q$ é verdadeira se p e q são ambas verdadeiras; se ao menos uma delas for falsa, $p \wedge q$ é falsa.

p	q	p $\wedge$ q
V	V	V
V	F	F
F	V	F
F	F	F

```r
# E (&)
(2 > 1) & (3 != 0)
```

```
## [1] TRUE
```

```r
(3 < 2) & (5 < 11)
```

```
## [1] FALSE
```

- A disjunção $p \vee q$ é verdadeira se p e q se ao menos uma das proposições p ou q é verdadeira; se p e q são ambas falsas, então $p \vee q$ é falsa.

p	q	p V q
V	V	V
V	F	V
F	V	V
F	F	F

```r
# OU (|)
(3 < 2) | (5 < 11)
```

```
## [1] TRUE
```

```r
(5 == 6) | (12 < 8)
```

```
## [1] FALSE
```

1.2 Objetos, Tipos de Dados e Variáveis

Em R praticamente tudo é um objeto: um número, uma palavra, um vetor contendo diversos números, uma tabela contendo diferentes vetores, uma lista contendo várias tabelas...as coisas podem ficar tão complicadas quanto se queira.

1.2.1 Vetores

Vetores são objetos formados por dados de um mesmo tipo. Um vetor pode conter nenhum, um ou mais valores. Alguns dos principais tipos de dados são:

- `logical`: `TRUE` ou `FALSE`
- `integer`: números inteiros
- `numeric` ou `double`: números reais
- `character`: texto

```r
# Para atribuir um valor a uma variável utilizados "<-" ou então "=".
# Não confundiro o = de atribuição com o == operador lógico.
# Vetores podem ser criados, ou concatenados como veremos mais adiante,
# utilizando a função c().

# Criando a variável vetor_vazio e deixando ela vazia
vetor_vazio <- c()
# Imprimindo a variável vetor_vazio
vetor_vazio
```

```
## NULL
```

```r
# Podemos atribuir apenas um valor a uma variável
var_texto <- "Palavra"
var_texto
```

```
## [1] "Palavra"
```

```r
# Podemos atribuir qualquer valor a uma variável
var_numerica <- 3*(5 + 2)
var_numerica
```

```
## [1] 21
```

```r
# Criando um vetores com três valores
var_texto <- c("Palavra","Word","Mot")
var_texto
```

```
## [1] "Palavra" "Word"    "Mot"
```

```r
# Criando um vetor lógico
var_logico = c(3 + 4 < 5, 2 == 1 + 1)
var_logico
```

```
## [1] FALSE  TRUE
```

Para apagar uma variável, utilizamos a função rm(). Aprenderemos sobre funções mais adiante. A princípio basta saber que dentro da função rm() colocaremos o nome das varíaveis que queremos apagar.

```r
# Apagando as variáveis var_logico, var_numerica e var_texto
# criadas anteriormente
rm(var_logico, var_numerica, var_texto)

# Para apagar todas as variáveis
# Use com cuidado!
rm(list = ls())
```

1.2.2 Data frames

Podemos agrupar vetores em um data frame. Em R, data frames são tabelas bidimensionais, semelhantes às planilhas do Excel. Este tipo de objeto será o mais utilizado em nosso dia-a-dia.

Vamos construir um data frame dos estados da região sudeste do Brasil, com as informações de nome, sigla, nome da capital, código DDD da capital e se a capital possui acesso para o mar.

```r
# Criando um data frame:
estados_sudeste <- data.frame(
  estado = c("Rio de Janeiro", "Sao Paulo", "Minas Gerais","Espirito Santo"),
  sigla = c("RJ", "SP", "MG", "ES"),
  capital = c("Rio de Janeiro", "Sao Paulo", "Belo Horizonte", "Vitoria"),
  DDD_capital = c(21, 11, 31, 27),
  mar_na_capital = c(TRUE, FALSE, FALSE, TRUE)
)

estados_sudeste
```

```
##           estado sigla        capital DDD_capital mar_na_capital
## 1 Rio de Janeiro    RJ Rio de Janeiro          21           TRUE
## 2      Sao Paulo    SP      Sao Paulo          11          FALSE
## 3   Minas Gerais    MG Belo Horizonte          31          FALSE
## 4 Espirito Santo    ES        Vitoria          27           TRUE
```

Esse procedimento funciona para data frames pequenos, mas não é difícil notar que se torna uma tarefa trabalhosa conforme aumenta-se o número de observações e variáveis. Felizmente, o R permite importar dados de outras fontes, o que aprenderemos a fazer em breve.

1.3 Funções

Funções são ferramentas, porções de código reutilizáveis. Elas nos permitem realizar os mais variados tipos de operações, seja criar ou modificar objetos,

realizar comandos no computador, e muito mais.

Funções quase sempre recebem argumentos, de forma a ajustar seu comportamento de acordo com algum objetivo específico. Alguns argumentos são obrigatórios, outros opicionais, ou seja, possuem valores pré-definidos.

Caso queira obter mais informações sobre uma função, você pode acessar sua documentação. A documentação contém tudo, ou a maior parte, do que se precisa saber sore uma função: quais seus argumentos, como eles se comportam, quais os valores pré-definidos. Para acessar a documentação basta digitar um ponto de interrogação seguido do nome da função.

Para aprendermos a usar algumas funções essenciais, usaremos o dataset `USArrests`, que contém dados sobre criminalidade nos 50 estados dos EUA no ano de 1973, e já vem pré-carregado no R. Assim, não precisaremos importar nada.

1.3.1 Explorando os dados

```
# Vendo a estrutura dos dados:
str(USArrests)
```

```
## 'data.frame':    50 obs. of  4 variables:
##  $ Murder  : num  13.2 10 8.1 8.8 9 7.9 3.3 5.9 15.4 17.4 ...
##  $ Assault : int  236 263 294 190 276 204 110 238 335 211 ...
##  $ UrbanPop: int  58 48 80 50 91 78 77 72 80 60 ...
##  $ Rape    : num  21.2 44.5 31 19.5 40.6 38.7 11.1 15.8 31.9 25.8 ...
```

```
# Vendo um resumo dos dados:
summary(USArrests)
```

```
##      Murder          Assault         UrbanPop          Rape
##  Min.   : 0.800   Min.   : 45.0   Min.   :32.00   Min.   : 7.30
##  1st Qu.: 4.075   1st Qu.:109.0   1st Qu.:54.50   1st Qu.:15.07
##  Median : 7.250   Median :159.0   Median :66.00   Median :20.10
##  Mean   : 7.788   Mean   :170.8   Mean   :65.54   Mean   :21.23
##  3rd Qu.:11.250   3rd Qu.:249.0   3rd Qu.:77.75   3rd Qu.:26.18
##  Max.   :17.400   Max.   :337.0   Max.   :91.00   Max.   :46.00
```

```
# Vendo as primeiras observações:
head(USArrests)
```

```
##            Murder Assault UrbanPop Rape
```

```
## Alabama      13.2     236       58 21.2
## Alaska       10.0     263       48 44.5
## Arizona       8.1     294       80 31.0
## Arkansas      8.8     190       50 19.5
## California    9.0     276       91 40.6
## Colorado      7.9     204       78 38.7
```

```
# Vendo as últimas observações:
tail(USArrests)
```

```
##               Murder Assault UrbanPop Rape
## Vermont          2.2      48       32 11.2
## Virginia         8.5     156       63 20.7
## Washington       4.0     145       73 26.2
## West Virginia    5.7      81       39  9.3
## Wisconsin        2.6      53       66 10.8
## Wyoming          6.8     161       60 15.6
```

```
# Número de linhas:
nrow(USArrests)
```

```
## [1] 50
```

```
# Número de colunas:
ncol(USArrests)
```

```
## [1] 4
```

Como vimos anteriormente, um `data frame` é uma representação tabular, onde cada linha corresponde a uma observação e cada coluna uma variável, ou atributo. Para obtermos uma coluna específica de um `data frame`, podemos utilizar o símbolo `$`.

```
# Selecionando apenas a coluna Murder:
USArrests$Murder
```

```
##  [1] 13.2 10.0  8.1  8.8  9.0  7.9  3.3  5.9 15.4 17.4  5.3  2.6 10.4  7.2  2.2
## [16]  6.0  9.7 15.4  2.1 11.3  4.4 12.1  2.7 16.1  9.0  6.0  4.3 12.2  2.1  7.4
## [31] 11.4 11.1 13.0  0.8  7.3  6.6  4.9  6.3  3.4 14.4  3.8 13.2 12.7  3.2  2.2
## [46]  8.5  4.0  5.7  2.6  6.8
```

```r
# Classe de um objeto:
class(USArrests$Murder)
```

```
## [1] "numeric"
```

```r
# Mínimo:
min(USArrests$Murder)
```

```
## [1] 0.8
```

```r
# Máximo:
max(USArrests$Murder)
```

```
## [1] 17.4
```

```r
# Somatório:
sum(USArrests$Murder)
```

```
## [1] 389.4
```

```r
# Comprimento de um vetor:
length(USArrests$Murder)
```

```
## [1] 50
```

```r
# Ordenar um vetor em ordem crescente:
sort(USArrests$Murder)
```

```
##  [1]  0.8  2.1  2.1  2.2  2.2  2.6  2.6  2.7  3.2  3.3  3.4  3.8  4.0  4.3  4.4
## [16]  4.9  5.3  5.7  5.9  6.0  6.0  6.3  6.6  6.8  7.2  7.3  7.4  7.9  8.1  8.5
## [31]  8.8  9.0  9.0  9.7 10.0 10.4 11.1 11.3 11.4 12.1 12.2 12.7 13.0 13.2 13.2
## [46] 14.4 15.4 15.4 16.1 17.4
```

```r
# A função sort possui o argumento opcional decreasing = FALSE.
# Para ordenar a lista de forma decrescente, podemos alterá-lo.
sort(USArrests$Murder, decreasing = TRUE)
```

```
##  [1] 17.4 16.1 15.4 15.4 14.4 13.2 13.2 13.0 12.7 12.2 12.1 11.4 11.3 11.1 10.4
## [16] 10.0  9.7  9.0  9.0  8.8  8.5  8.1  7.9  7.4  7.3  7.2  6.8  6.6  6.3  6.0
## [31]  6.0  5.9  5.7  5.3  4.9  4.4  4.3  4.0  3.8  3.4  3.3  3.2  2.7  2.6  2.6
## [46]  2.2  2.2  2.1  2.1  0.8
```

1.3.2 Estatísticas Descritivas

Vamos usar agora outras colunas para calcularmos estatísticas descritivas utilizando funções do R.

```
# Média:
mean(USArrests$Assault)
```

```
## [1] 170.76
```

```
# Mediana:
median(USArrests$Assault)
```

```
## [1] 159
```

```
# Quantis:
quantile(USArrests$Assault)
```

```
##   0%  25%  50%  75% 100%
##   45  109  159  249  337
```

```
# Variância:
var(USArrests$Assault)
```

```
## [1] 6945.166
```

```
# Desvio padrão:
sd(USArrests$Assault)
```

```
## [1] 83.33766
```

```
# Covariância:
cov(USArrests$Assault, USArrests$Murder)
```

```
## [1] 291.0624
```

```
# Correlação:
cor(USArrests$Assault, USArrests$Murder)
```

```
## [1] 0.8018733
```

Ao resultado de uma função pode ser aplicada outra função, o que é chamado de aninhamento. Vamos supor, por exemplo que queiremos arredondar, com três casas decimais, o valor calculado para a correlação entre as variáveis `Assault` e `Murder`.

```
# A função utilizada para arredondar um número é round().
# Para que tenha 2 casa decimais, precisaremos ajustar o parâmetro digits.
round(cor(USArrests$Assault, USArrests$Murder), digits = 3)
```

```
## [1] 0.802
```

1.3.3 Criação de vetores

Vamos conhecer algumas funções que podem ser usadas para criar vetores numéricos de forma fácil.

```
# Criar um vetor de com o valor x repetido n vezes:
rep(2, 3)
```

```
## [1] 2 2 2
```

```
# Criar uma sequencia de números: seq()
seq(from = 1, to = 50, by = 3)
```

```
##  [1]  1  4  7 10 13 16 19 22 25 28 31 34 37 40 43 46 49
```

```
# Podemos substituir, por exemplo seq(from = x, to = y, by = 1)
3:15
```

```
##  [1]  3  4  5  6  7  8  9 10 11 12 13 14 15
```

```
# Vamos atribuir os valores anteriormente encontrados a variáveis:
var1 <- rep(2, 3)
var2 <- seq(from = 1, to = 50, by = 3)

# Para concatenar vetores, utilizamos a função c()
meu_vetor <- c(var1, var2)
meu_vetor
```

```
##  [1]  2  2  2  1  4  7 10 13 16 19 22 25 28 31 34 37 40 43 46 49
```

1.3.4 Amostragem

O R foi uma linguagem criada por estatísticos e até hoje possui como um de seus pontos fortes sua capacidade de lidar com amostragem e simulações.

```
# Permutação aleatórias dos números naturais menores que 7:
sample(7)
```

```
## [1] 1 5 7 6 2 3 4
```

```
# Permutação aleatória dos números entre 2 e 5:
sample(2:5)
```

```
## [1] 3 2 5 4
```

```
# Sorteio, sem reposição, de 5 números aleatórios
# da variável var2 que criamos anteriormente:
sample(var2, 5)
```

```
## [1] 19 10 25 13 46
```

```
# Sorteio, com reposição, de 6 números aleatórios entre 1 e 4:
sample(1:4, size = 6, replace = TRUE)
```

```
## [1] 2 2 3 3 1 1
```

```
# Sorteio, sem reposição, de uma palavra em uma lista:
sample(c("pera", "uva", "banana", "caqui"), 1)
```

```
## [1] "banana"
```

Para replicar um experimento utilizando funções que produzem resultados aleatórios, precisamos definir uma "semente". Ela faz com que o computador gere sempre os mesmos números. Para tanto utilizamos a função set.seed(n), onde n é um número inteiro qualquer (um dado número sempre gerará o mesmo resultado). Preferencialmente deve estar no começo do seu script, sempre antes de rodar as funções.

```
# Definindo 42 como a semente, poderia ser qualquer
# outro número.
set.seed(42)
```

1.4 Baixando e excutando pacotes externos

Até agora utilizamos apenas funções pré-instaladas no R. Para ter acesso a novos pacotes, será necessário instalá-los primeiro. Esse procedimento só é necessário ser feito uma vez, a não ser que o R precise ser reinstalado. Sempre que iniciar uma sessão será necessário carregar os pacotes que serão utilizados.

```
# Instalando o tidyverse
install.packages("tidyverse")

# Carregando o tidyverse
library("tidyverse")
```

O `tidyverse` é um conjunto de pacotes que juntos fornecem uma ampla gama de ferramentas para análise de dados. Algumas dessas ferramentas apresentam versões otimizadas de funções já existentes no R.

O operador pipe (`%>%`) permite substituir o aninhamento de funções por uma cadeia de operação, o que torna os códigos mais legíveis. Veremos aplicações do pipe e de algumas dos principais pacotes e funções do `tidyverse` nos capítulos posteriores.

Capítulo 2

Importação

O R nos permite importar e utilizar em nossas análises uma série de diferentes tipos de arquivos. Isso pode ser feito por meio de funções nativas ou através de ferramentas disponíveis em pacotes criados por outros usuários. Por exemplo, o `tidyverse` possui os pacotes `readr`, que permite a leitura de arquivos como .csv, .fwf e .txt, e o pacote `readxl`, para leitura de arquivos Excel.

2.1 Arquivos separados por vírgula (.csv)

Comma-separated values é um formato de arquivo de texto onde as observações de uma tabela são representadas por linhas e as colunas são separadas por vírgula (no padrão americano) ou ponto-e-vírgula (no padrão europeu e brasileiro). No padrão separado por vírgula, o indicador decimal é o ponto; no padrãos separado por ponto-e-vírgula, a vírcula. É importante estar atento ao tipo de arquivo que estamos lidando.

O dataset `gapminder` contém dados econômicos e demográficos para diversos países a cada 5 anos de 1952 a 2007. O arquivo que usaremos como exemplo apresenta uma amostra contendo as informações disponíveis para o Brasil, Botsuana e Coréia do Sul. Ele foi salvo em .csv com padrão separado por ponto-e-vírgula.

```
# Primeira forma: ajustando os parâmetros da função read.csv
gapminderCountries <- read.csv("Aula1/gapminderCountries.csv",
                               sep = ";",
                               dec = ",")

# Segunda forma: utilizando a função read.csv2
gapminderCountries <- read.csv2("Aula1/gapminderCountries.csv")
```

```r
# Mostrando um pedaço do dataset
head(gapminderCountries)
```

```
##    country continent year lifeExp    pop gdpPercap
## 1 Botswana    Africa 1952  47.622 442308  851.2411
## 2 Botswana    Africa 1957  49.618 474639  918.2325
## 3 Botswana    Africa 1962  51.520 512764  983.6540
## 4 Botswana    Africa 1967  53.298 553541 1214.7093
## 5 Botswana    Africa 1972  56.024 619351 2263.6111
## 6 Botswana    Africa 1977  59.319 781472 3214.8578
```

Para maiores informações, leia a documentação das funções `read.csv` e `read.csv2`.

2.2 Arquivos Excel (.xls e .xlsx)

O Microsoft Excel é um dos *softwares* de planilha mais populares do mundo. São muito utilizados não só no meio corporativo, mas também no meio acadêmico. Apesar de limitações principalmente relacionadas a lidar com datas e tabelas muito grandes, é uma ferramenta poderosa e torna-se ainda melhor se aliada ao R.

O `tidyverse` não carrega automaticamente o pacote necessário para ler arquivos Excel, portanto, precisaremos carregar o `readxl`. Utilizaremos como exemplo uma amostra do dataset `gapminder`, mas desta vez contendo informações para todos os países no ano de 2007.

```r
# Carregando o pacote necessário
library(readxl)

# Importando o arquivo de interesse
gapminder2007 <- read_excel("Aula1/gapminder2007.xlsx")

# Mostrando um pedaço do dataset
head(gapminder2007)
```

```
## # A tibble: 6 x 6
##   country     continent  year lifeExp      pop gdpPercap
##   <chr>       <chr>     <dbl>   <dbl>    <dbl>     <dbl>
## 1 Afghanistan Asia       2007    43.8 31889923      975.
## 2 Albania     Europe     2007    76.4  3600523     5937.
## 3 Algeria     Africa     2007    72.3 33333216     6223.
```

```
## 4 Angola      Africa     2007    42.7 12420476     4797.
## 5 Argentina   Americas   2007    75.3 40301927    12779.
## 6 Australia   Oceania    2007    81.2 20434176    34435.
```

Capítulo 3

Visualização

A visualização pode ser utilizada tanto para conhecer os dados com que iremos trabalhar, quanto para comunicar com ao público aquilo que descobrimos. Para tanto, o `tidyverse` fornece o pacote `ggplot2`, uma ferramenta poderossíma!

Ele permite construir desde gráficos simples até visualizações extremamente elaboradas, onde diversas variáveis são mapeadas em diferentes atributos de um gráfico. Somado a outras ferramentas, o `ggplot2` também pode ser utilizado para a construção de mapas.

3.1 Gráfico de linha

Gráficos de linhas são muito utilizados para mostrar tendências ao longo do tempo. Utilizando o dataset `gapminderCountries` que contruímos anteriormente, poderemos ver de que forma o PIB per capita de Brasil, Botsuana e Coreia do Sul se comportaram ao longo do tempo.

```
gapminderCountries %>%
  ggplot() +
  geom_line(aes(x = year,
                y = gdpPercap/10^3,
                color = country)) +
  labs(title = "Gapminder",
       subtitle = "1957-2007",
       color = "País") +
  xlab("Ano") +
  ylab("PIB per capita \n (US$ mil)")
```

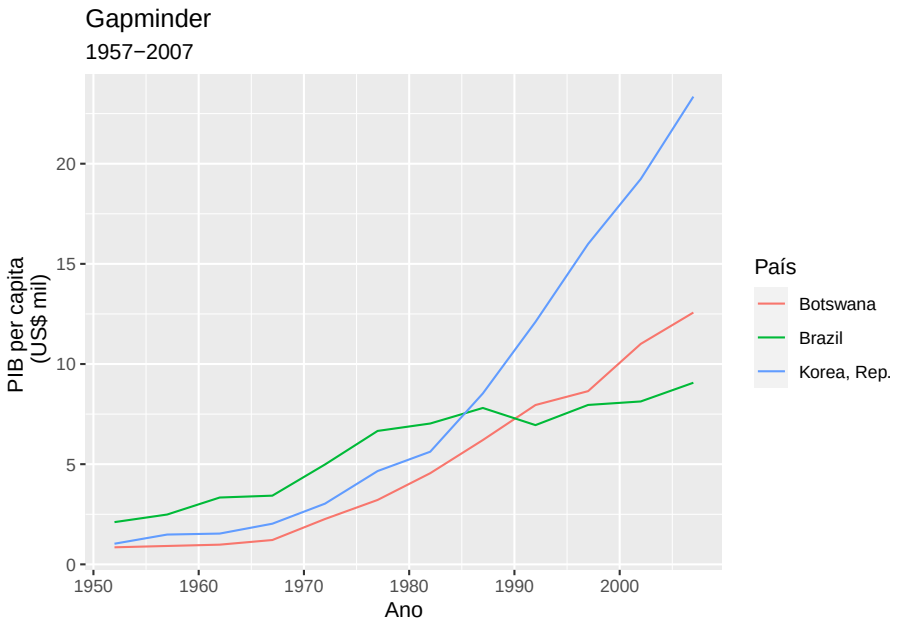

3.2 Gráfico de dispersão

Gráficos de dispersão permitem visualizar a relação entre duas variáveis numéricas, o que nos permite visualizar possíveis correlações. Utilizaremos o dataset `gapminder2007` para ver de que forma o PIB per capita está relacionado à expectativa de vida nos diferentes países do mundo em 2007.

Desta vez poderemos mostrar de que forma o `ggplot2` pode mapear diferentes atributos das observações em um mesmo gráfico. Em nosso exemplo, cada ponto representa um país, cada cor um continente, e o tamanho dos pontos é dado por sua população.

```
gapminder2007 %>%
  ggplot() +
  geom_point(aes(x = gdpPercap/10^3,
                 y = lifeExp,
                 color = continent,
                 size = pop/10^6)) +
  labs(title = "Gapminder",
       subtitle = "2007",
       color = "Continente",
       size = "População \n (milhões de habitantes)") +
  xlab("PIB per capita \n (US$ mil)") +
  ylab("Expectativa de Vida \n (anos)")
```

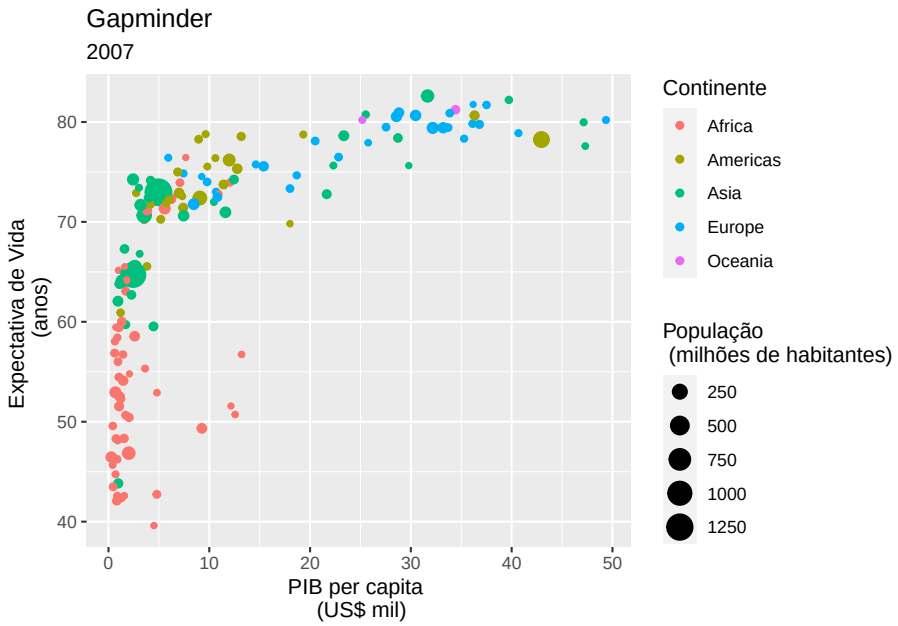


```
# Salvando o gráfico
# Função ggsave salva o último gráfico mostrado
ggsave(filename = "gapminder2007.png",
       path = "Aula1/")
```

```
## Saving 6.5 x 4.5 in image
```

Capítulo 4

Organização e Transformação

A maior parte do tempo gasto ao trabalhar com dados deve-se a atividades de limpeza, oganização e transformação. Muitas vezes, os dados que obtemos estão desorganizados ou ainda não apresentam o formato que desejamos.

Além disso, é comum querermos versos sintéticas dos dados seja para construir tabelas ou gráficos que estejam em formatos apropriados para publicação.

O `tidyverse` oferece uma série de ferramentas que facilitam a atividade de limpeza de dados. O operador pipe `%>%` e conjunto dos chamados *verbs*, funções que permitem construir encadeamentos de operações para organização de dados.

Os principais *verbs* que veremos serão: `mutate`, `select`, `filter`, `summarise`, `arrange` e `group_by`. Vamos retornar ao dataset `gapminder` para experimentarmos com essas funções e algumas outras que já utilizamos.

```
library(gapminder)

# Vendo de que forma o dataset está organizado
head(gapminder)
```

```
## # A tibble: 6 x 6
##   country     continent  year lifeExp      pop gdpPercap
##   <fct>       <fct>     <int>   <dbl>    <int>     <dbl>
## 1 Afghanistan Asia       1952    28.8  8425333      779.
## 2 Afghanistan Asia       1957    30.3  9240934      821.
## 3 Afghanistan Asia       1962    32.0 10267083      853.
## 4 Afghanistan Asia       1967    34.0 11537966      836.
## 5 Afghanistan Asia       1972    36.1 13079460      740.
## 6 Afghanistan Asia       1977    38.4 14880372      786.
```

4.1 `mutate`: Criando nova coluna

Sabemos que o PIB per capita é a razão entre o PIB e a população. Caso desejemos recuperar o PIB a partir das informações que temos, podemos utilizara função `mutate`.

```
gapminder %>%
  mutate(gdp = pop*gdpPercap) %>%
  head()
```

```
## # A tibble: 6 x 7
##   country     continent  year lifeExp      pop gdpPercap          gdp
##   <fct>       <fct>     <int>   <dbl>    <int>     <dbl>        <dbl>
## 1 Afghanistan Asia       1952    28.8  8425333      779.  6567086330.
## 2 Afghanistan Asia       1957    30.3  9240934      821.  7585448670.
## 3 Afghanistan Asia       1962    32.0 10267083      853.  8758855797.
## 4 Afghanistan Asia       1967    34.0 11537966      836.  9648014150.
## 5 Afghanistan Asia       1972    36.1 13079460      740.  9678553274.
## 6 Afghanistan Asia       1977    38.4 14880372      786. 11697659231.
```

4.2 `select`: Selecionando colunas

A função `select` permite especificar quais colunas queremos manter em nosso data frame. Essa função é muito útil quando trabalhamos com bases de dados muito grandes onde algumas colunas não são de nosso interesse ou são redundantes.

Se quisermos construir um data frame apenas com as colunas `country`, `year`, `lifeExp`e `pop`:

```
gapminder %>%
  select(country, year, lifeExp, pop) %>%
  head()
```

```
## # A tibble: 6 x 4
##   country      year lifeExp      pop
##   <fct>       <int>   <dbl>    <int>
## 1 Afghanistan  1952    28.8  8425333
## 2 Afghanistan  1957    30.3  9240934
## 3 Afghanistan  1962    32.0 10267083
## 4 Afghanistan  1967    34.0 11537966
## 5 Afghanistan  1972    36.1 13079460
## 6 Afghanistan  1977    38.4 14880372
```

Para selecionarmos colunas adjacentes podemos usar dois pontos.

```
gapminder %>%
  select(country:lifeExp) %>%
  head()
```

```
## # A tibble: 6 x 4
##   country     continent  year lifeExp
##   <fct>       <fct>     <int>   <dbl>
## 1 Afghanistan Asia       1952    28.8
## 2 Afghanistan Asia       1957    30.3
## 3 Afghanistan Asia       1962    32.0
## 4 Afghanistan Asia       1967    34.0
## 5 Afghanistan Asia       1972    36.1
## 6 Afghanistan Asia       1977    38.4
```

Podemos dizer, também, quais colunas não queremos.

```
gapminder %>%
  select(-continent) %>%
  head()
```

```
## # A tibble: 6 x 5
##   country      year lifeExp      pop gdpPercap
##   <fct>       <int>   <dbl>    <int>     <dbl>
## 1 Afghanistan  1952    28.8  8425333      779.
## 2 Afghanistan  1957    30.3  9240934      821.
## 3 Afghanistan  1962    32.0 10267083      853.
## 4 Afghanistan  1967    34.0 11537966      836.
## 5 Afghanistan  1972    36.1 13079460      740.
## 6 Afghanistan  1977    38.4 14880372      786.
```

Dependendo do conjunto de coluna que desejamos, podemos combinar o que foi visto anteriormente.

```
gapminder %>%
  select(country:lifeExp,-continent,gdpPercap) %>%
  head()
```

```
## # A tibble: 6 x 4
##   country      year lifeExp gdpPercap
##   <fct>       <int>   <dbl>     <dbl>
## 1 Afghanistan  1952    28.8      779.
```

```
## 2 Afghanistan  1957    30.3      821.
## 3 Afghanistan  1962    32.0      853.
## 4 Afghanistan  1967    34.0      836.
## 5 Afghanistan  1972    36.1      740.
## 6 Afghanistan  1977    38.4      786.
```

4.3 `filter`: Aplicando filtros

Filtros permitem selecionar apenas linhas que atendam a um critério pré-estabelecido. Aqui os operadores lógicos que vimos no início da apostila serão essenciais.

Por exemplo, se quisermos selecionar apenas as observações relativas ao Brasil:

```
gapminder %>%
  filter(country == "Brazil") %>%
  head()
```

```
## # A tibble: 6 x 6
##   country continent  year lifeExp       pop gdpPercap
##   <fct>   <fct>     <int>   <dbl>     <int>     <dbl>
## 1 Brazil  Americas   1952    50.9  56602560     2109.
## 2 Brazil  Americas   1957    53.3  65551171     2487.
## 3 Brazil  Americas   1962    55.7  76039390     3337.
## 4 Brazil  Americas   1967    57.6  88049823     3430.
## 5 Brazil  Americas   1972    59.5 100840058     4986.
## 6 Brazil  Americas   1977    61.5 114313951     6660.
```

Se quisermos filtrar por mais de um país, utilizamos o operador `%in%`.

```
gapminder %>%
  filter(country %in% c("Brazil", "Argentina"))
```

```
## # A tibble: 24 x 6
##    country   continent  year lifeExp      pop gdpPercap
##    <fct>     <fct>     <int>   <dbl>    <int>     <dbl>
##  1 Argentina Americas   1952    62.5 17876956     5911.
##  2 Argentina Americas   1957    64.4 19610538     6857.
##  3 Argentina Americas   1962    65.1 21283783     7133.
##  4 Argentina Americas   1967    65.6 22934225     8053.
##  5 Argentina Americas   1972    67.1 24779799     9443.
##  6 Argentina Americas   1977    68.5 26983828    10079.
##  7 Argentina Americas   1982    69.9 29341374     8998.
```

```
##  8 Argentina Americas   1987    70.8 31620918     9140.
##  9 Argentina Americas   1992    71.9 33958947     9308.
## 10 Argentina Americas   1997    73.3 36203463    10967.
## # ... with 14 more rows
```

Podemos também combinar filtros.

```
gapminder %>%
  filter(country %in% c("Brazil", "Argentina"),
         year < 1977)
```

```
## # A tibble: 10 x 6
##    country   continent  year lifeExp       pop gdpPercap
##    <fct>     <fct>     <int>   <dbl>     <int>     <dbl>
##  1 Argentina Americas   1952    62.5  17876956     5911.
##  2 Argentina Americas   1957    64.4  19610538     6857.
##  3 Argentina Americas   1962    65.1  21283783     7133.
##  4 Argentina Americas   1967    65.6  22934225     8053.
##  5 Argentina Americas   1972    67.1  24779799     9443.
##  6 Brazil    Americas   1952    50.9  56602560     2109.
##  7 Brazil    Americas   1957    53.3  65551171     2487.
##  8 Brazil    Americas   1962    55.7  76039390     3337.
##  9 Brazil    Americas   1967    57.6  88049823     3430.
## 10 Brazil    Americas   1972    59.5 100840058     4986.
```

Note que poderíamos ter utilizado o operador `&` no lugar da vírgula. Agora, vamos utilizar o operador `|`.

```
gapminder %>%
  filter(year == 2007,
         continent == "Oceania" | country == "United States")
```

```
## # A tibble: 3 x 6
##   country       continent  year lifeExp       pop gdpPercap
##   <fct>         <fct>     <int>   <dbl>     <int>     <dbl>
## 1 Australia     Oceania    2007    81.2  20434176    34435.
## 2 New Zealand   Oceania    2007    80.2   4115771    25185.
## 3 United States Americas   2007    78.2 301139947    42952.
```

4.4 `group_by` e `summarise`: Sintetizando colunas

Se quisermos saber o PIB per capita médio para cada um dos continentes em 1972:

```
gapminder %>%
  filter(year == 1972) %>%
  group_by(continent) %>%
  summarise(avg_gdpPercap = mean(gdpPercap))
```

```
## # A tibble: 5 x 2
##   continent avg_gdpPercap
##   <fct>             <dbl>
## 1 Africa            2340.
## 2 Americas          6491.
## 3 Asia              8187.
## 4 Europe           12480.
## 5 Oceania          16417.
```

4.5 `arrange`: Ordenando as linhas de forma crescente ou decrescente

Quais os 5 países com menor expectativa de vida em 1987?

```
gapminder %>%
  filter(year == 1987) %>%
  arrange(lifeExp) %>%
  head(n = 5)
```

```
## # A tibble: 5 x 6
##   country       continent  year lifeExp      pop gdpPercap
##   <fct>         <fct>     <int>   <dbl>    <int>     <dbl>
## 1 Angola        Africa     1987    39.9  7874230     2430.
## 2 Sierra Leone  Africa     1987    40.0  3868905     1294.
## 3 Afghanistan   Asia       1987    40.8 13867957      852.
## 4 Guinea-Bissau Africa     1987    41.2   927524      736.
## 5 Mozambique    Africa     1987    42.9 12891952      390.
```

E os 5 países com maior expectativa?

```
gapminder %>%
  filter(year == 1987) %>%
  arrange(desc(lifeExp)) %>%
  head(n = 5)
```

```
## # A tibble: 5 x 6
```

```
##   country     continent  year lifeExp       pop gdpPercap
##   <fct>       <fct>     <int>   <dbl>     <int>     <dbl>
## 1 Japan       Asia       1987    78.7 122091325    22376.
## 2 Switzerland Europe     1987    77.4   6649942    30282.
## 3 Iceland     Europe     1987    77.2    244676    26923.
## 4 Sweden      Europe     1987    77.2   8421403    23587.
## 5 Spain       Europe     1987    76.9  38880702    15765.
```

4.6 Salvando seus resultados

Quando terminar de organizar seus dados, pode ser interessante salvá-lo para utilizar posteriormente ou compartilhar com alguém. Vamos reconstruir os datasets `gapminderCountries` e `gapminder2007` que utilizamos anteriormente e salvá-los em .csve .xlsx respectivamente.

4.6.1 Salvando arquivos separados por vírgula (.csv)

```
gapminderCountries <- gapminder %>%
  filter(country %in% c("Brazil", "Botswana", "Korea, Rep."))

# Salvando em padrão americano
write.csv(gapminderCountries, file = "Aula2/gapminderCountries.csv")
```

4.6.2 Salvando arquivos Excel (.xlsx)

```
gapminder2007 <- gapminder %>%
  filter(year == 2007)

# Precisaremos usar o pacote writexl
library(writexl)

# Salvando
write_xlsx(gapminder2007, "Aula2/gapminder2007.xlsx")
```

Capítulo 5

Modelagem

Após organizar nossos dados e obter as informações iniciais com as estatísticas descritivas, podemos dar mais um passo em nossa análise e buscar entender como as diferentes variáveis que temos a disposição se relacionam.

Para tanto, em economia e outras ciências socias, partimos de modelos teóricos para a estimação de relações empíricas entre variáveis dependentes (variável resposta) e independentes (variáveis explicativas), através de técnicas de regressão.

O R possui ferramentas para estimar diferentes tipos de modelo. A seguir veremos como funções que nos permitem estimar modelos lineares simples e múltiplos, probit e logit.

5.1 Regressão Linear

A regressão linear assume que a relação entre a variável dependente e as variáveis independentes é uma função linear dos parâmetros.

5.1.1 Regressão Linear Simples

Em uma regressão linear simples, a variável dependente é função de apenas uma variável independente mais um termo de erro. Ou seja, o modelo de regressão linear simples pode ser representado como:

$$y = \beta_0 + \beta_1 x + u$$

Onde y é a variável dependente, x a variável independente, β_0 e β_1 são os parâmetros e u é o termo de erro. Para estimar os parâmetros de um modelo de

regressão linear, comumente utiliza-se o método dos mínimos quadrados ordinários. Em R, utilizaremos a função `lm` para estimar modelos lineares.

Para os exemplos, utilizaremos o pacote `wooldrige` que fornece os dataset usados como exemplo no livro "Introductory Econometrics: A Modern Approach, 7ed" do economista Profº Jeffrey Wooldridge.

```
# Carregando o pacote wooldrige
library(wooldridge)
```

```
# Carregando o dataset wage1
wage1 <- wooldridge::wage1

# Vendo a estrutura do dataset
str(wage1)
```

```
## 'data.frame':    526 obs. of  24 variables:
##  $ wage    : num  3.1 3.24 3 6 5.3 ...
##  $ educ    : int  11 12 11 8 12 16 18 12 12 17 ...
##  $ exper   : int  2 22 2 44 7 9 15 5 26 22 ...
##  $ tenure  : int  0 2 0 28 2 8 7 3 4 21 ...
##  $ nonwhite: int  0 0 0 0 0 0 0 0 0 0 ...
##  $ female  : int  1 1 0 0 0 0 0 1 1 0 ...
##  $ married : int  0 1 0 1 1 1 0 0 0 1 ...
##  $ numdep  : int  2 3 2 0 1 0 0 0 2 0 ...
##  $ smsa    : int  1 1 0 1 0 1 1 1 1 1 ...
##  $ northcen: int  0 0 0 0 0 0 0 0 0 0 ...
##  $ south   : int  0 0 0 0 0 0 0 0 0 0 ...
##  $ west    : int  1 1 1 1 1 1 1 1 1 1 ...
##  $ construc: int  0 0 0 0 0 0 0 0 0 0 ...
##  $ ndurman : int  0 0 0 0 0 0 0 0 0 0 ...
##  $ trcommpu: int  0 0 0 0 0 0 0 0 0 0 ...
##  $ trade   : int  0 0 1 0 0 0 1 0 1 0 ...
##  $ services: int  0 1 0 0 0 0 0 0 0 0 ...
##  $ profserv: int  0 0 0 0 0 1 0 0 0 0 ...
##  $ profocc : int  0 0 0 0 0 1 1 1 1 1 ...
##  $ clerocc : int  0 0 0 1 0 0 0 0 0 0 ...
##  $ servocc : int  0 1 0 0 0 0 0 0 0 0 ...
##  $ lwage   : num  1.13 1.18 1.1 1.79 1.67 ...
##  $ expersq : int  4 484 4 1936 49 81 225 25 676 484 ...
##  $ tenursq : int  0 4 0 784 4 64 49 9 16 441 ...
##  - attr(*, "time.stamp")= chr "25 Jun 2011 23:03"
```

```
# Utilizando a função lm
my_model <- lm(formula = wage ~ educ, data = wage1)
```

```r
# Mostrando os resultados do modelo
summary(my_model)
```

```
##
## Call:
## lm(formula = wage ~ educ, data = wage1)
##
## Residuals:
##     Min      1Q  Median      3Q     Max
## -5.3396 -2.1501 -0.9674  1.1921 16.6085
##
## Coefficients:
##             Estimate Std. Error t value Pr(>|t|)
## (Intercept) -0.90485    0.68497  -1.321    0.187
## educ         0.54136    0.05325  10.167   <2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 3.378 on 524 degrees of freedom
## Multiple R-squared:  0.1648, Adjusted R-squared:  0.1632
## F-statistic: 103.4 on 1 and 524 DF,  p-value: < 2.2e-16
```

Utilizamos o dataset `wage1` para estimar o modelo ecométrico

$$wage = \beta_0 + \beta 1 educ + u$$

Onde *wage* é medido em dólares por hora e *educ* são os anos de educação dos indivíduos da amostra. β_1 mede o efeito médio de um ano a mais de estudo no salário, tudo o mais constante. Podemos visualizar graficamente a relação.

```r
wage1 %>%
  ggplot(aes(x = educ, y = wage)) +
  geom_point() +
  geom_smooth(method = lm, se = FALSE) +
  theme_classic()
```

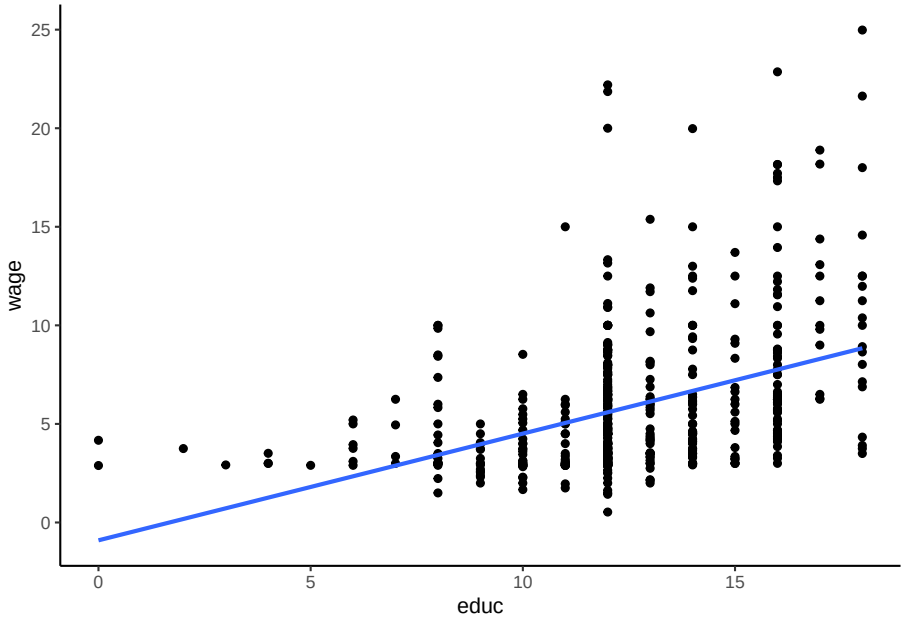

A variável `my_model` contém as informações do nosso modelo. Podemos acessar informações de interesse como o valor do R^2, os parâmetros e os resídios por meio dos atributos de `my_model`.

```
# Coeficientes
my_model$coefficients
```

```
## (Intercept)        educ
##  -0.9048516   0.5413593
```

```
# Informações sobre os coeficientes
summary(my_model)$coefficients
```

```
##               Estimate Std. Error   t value     Pr(>|t|)
## (Intercept) -0.9048516 0.68496782 -1.321013 1.870735e-01
## educ         0.5413593 0.05324804 10.166746 2.782599e-22
```

```
# R^2
summary(my_model)$r.squared
```

```
## [1] 0.1647575
```

```r
# R^2 ajustado
summary(my_model)$adj.r.squared
```

```
## [1] 0.1631635
```

```r
# Estatísticas descritivas dos resíduos
summary(my_model$residuals)
```

```
##    Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
## -5.3396 -2.1501 -0.9674  0.0000  1.1921 16.6085
```

5.1.2 Regressão Linear Múltipla

Em um modelo de regressão linear multiplo, a variável dependente é função de múltiplas variáveis independentes. Ou seja,

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \cdots + \beta_n x_n + u$$

Novamente utilizaremos o dataset `wage1`. Desta vez, para estimar o modelo

$$wage = \beta_0 + \beta_1 educ + \beta_2 exper + u$$

```r
# Criando um novo modelo
my_model2 <- lm(wage ~ educ + exper, data = wage1)

# Mostrando resultados da regressão
summary(my_model2)
```

```
##
## Call:
## lm(formula = wage ~ educ + exper, data = wage1)
##
## Residuals:
##     Min      1Q  Median      3Q     Max
## -5.5532 -1.9801 -0.7071  1.2030 15.8370
##
## Coefficients:
##             Estimate Std. Error t value Pr(>|t|)
## (Intercept) -3.39054    0.76657  -4.423 1.18e-05 ***
## educ         0.64427    0.05381  11.974  < 2e-16 ***
## exper        0.07010    0.01098   6.385 3.78e-10 ***
## ---
```

```
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 3.257 on 523 degrees of freedom
## Multiple R-squared:  0.2252, Adjusted R-squared:  0.2222
## F-statistic: 75.99 on 2 and 523 DF,  p-value: < 2.2e-16
```

Podemos realizar utilizar a notação da fórmula de forma a alterar a especificação do modelo, por exemplo, incluir um termo quadrático, ou estimar um modelo sem intercepto.

```
# Estimando o modelo anterior sem intercepto
lm(wage ~ educ + exper - 1, data = wage1)
```

```
##
## Call:
## lm(formula = wage ~ educ + exper - 1, data = wage1)
##
## Coefficients:
##    educ    exper
## 0.41705  0.04544
```

Vamos utilizar esses dados para estimar uma equação minceriana do tipo

$$\ln wage = \beta_0 + \beta_1 educ + \beta_2 exper + \beta_2 exper^2 + \gamma' x + u$$

Onde *wage*, é o salário em dólares por hora, *educ* são os anos de estudo, *exper* os anos de experiência profissional e x um vetor de características observáveis, como raça, gênero e status marital. Podemos estimar os parâmetros utilizando R da seguinte forma.

```
# Equação Minceriana
wage1 %>%
  lm(log(wage) ~ educ + exper + I(exper^2) + nonwhite + female + married, data = .) %>%
  summary()
```

```
##
## Call:
## lm(formula = log(wage) ~ educ + exper + I(exper^2) + nonwhite +
##     female + married, data = .)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -1.79493 -0.27927 -0.01887  0.26057  1.27372
```

```
##
## Coefficients:
##               Estimate Std. Error t value Pr(>|t|)
## (Intercept)  0.3954849  0.1030918   3.836  0.00014 ***
## educ         0.0826774  0.0070297  11.761  < 2e-16 ***
## exper        0.0358161  0.0052508   6.821 2.52e-11 ***
## I(exper^2)  -0.0006334  0.0001131  -5.600 3.48e-08 ***
## nonwhite    -0.0147385  0.0597847  -0.247  0.80537
## female      -0.3293054  0.0367083  -8.971  < 2e-16 ***
## married      0.0638034  0.0422190   1.511  0.13133
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 0.4133 on 519 degrees of freedom
## Multiple R-squared:  0.4024, Adjusted R-squared:  0.3955
## F-statistic: 58.24 on 6 and 519 DF,  p-value: < 2.2e-16
```

5.2 Logit

Usaremos o dataset `cps91` do pacote `wooldrige` para exemplificar o uso da função `glm` que permite estimar modelos logit e probit. O exemplo consiste de um modelo para explicar a participação das mulheres casadas na força de trabalho.

```
# Lendo o dataset
cps91 <- wooldridge::cps91

# Estimando modelo Logit
cps91 %>%
  glm(inlf ~ nwifeinc + educ + exper + I(exper^2) +
        age + kidlt6 + kidge6,
      family = binomial(link = "logit"),
      data = .) %>%
  summary()
```

```
##
## Call:
## glm(formula = inlf ~ nwifeinc + educ + exper + I(exper^2) + age +
##     kidlt6 + kidge6, family = binomial(link = "logit"), data = .)
##
## Deviance Residuals:
##     Min       1Q   Median       3Q      Max
## -2.1504  -1.1642   0.7221   0.9986   2.2435
##
```

```
## Coefficients:
##               Estimate Std. Error z value Pr(>|z|)
## (Intercept) -2.4284265  8.5368907  -0.284  0.77606
## nwifeinc    -0.0150524  0.0011200 -13.440  < 2e-16 ***
## educ        -0.0899159  1.4241121  -0.063  0.94966
## exper       -0.2466021  1.4250709  -0.173  0.86262
## I(exper^2)  -0.0009311  0.0002833  -3.286  0.00102 **
## age          0.2574374  1.4240344   0.181  0.85654
## kidlt6      -0.7874204  0.0852829  -9.233  < 2e-16 ***
## kidge6       0.0608807  0.0779442   0.781  0.43476
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## (Dispersion parameter for binomial family taken to be 1)
##
##     Null deviance: 7653.5  on 5633  degrees of freedom
## Residual deviance: 7075.2  on 5626  degrees of freedom
## AIC: 7091.2
##
## Number of Fisher Scoring iterations: 4
```

5.3 Probit

```
# Estimando modelo Probit
cps91 %>%
  glm(inlf ~ nwifeinc + educ + exper + I(exper^2) +
        age + kidlt6 + kidge6,
      family = binomial(link = "probit"),
      data = .) %>%
  summary()
```

```
##
## Call:
## glm(formula = inlf ~ nwifeinc + educ + exper + I(exper^2) + age +
##     kidlt6 + kidge6, family = binomial(link = "probit"), data = .)
##
## Deviance Residuals:
##     Min       1Q   Median       3Q      Max
## -2.1969  -1.1654   0.7229   1.0024   2.2976
##
## Coefficients:
##               Estimate Std. Error z value Pr(>|z|)
## (Intercept) -1.4892097  5.3413422  -0.279  0.78039
```

```
## nwifeinc    -0.0091475  0.0006762 -13.528  < 2e-16 ***
## educ        -0.0626141  0.8909676  -0.070  0.94397
## exper       -0.1571615  0.8915253  -0.176  0.86007
## I(exper^2)  -0.0005574  0.0001719  -3.243  0.00118 **
## age          0.1631290  0.8909229   0.183  0.85472
## kidlt6      -0.4810831  0.0516287  -9.318  < 2e-16 ***
## kidge6       0.0409159  0.0472457   0.866  0.38648
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## (Dispersion parameter for binomial family taken to be 1)
##
##     Null deviance: 7653.5  on 5633  degrees of freedom
## Residual deviance: 7076.8  on 5626  degrees of freedom
## AIC: 7092.8
##
## Number of Fisher Scoring iterations: 4
```

Capítulo 6

Dicas para Continuar os Estudos